

Esperimento C — Report aggregato

1. Dataset

ID	Ordine	NCS oss. base	NCS oss. BS	NCS perc. base	NCS perc. BS	Lat. base	Lat. BS	AVOR	Estrazione
P001	BS→base	2/3	3/3	2/3	3/3	1,43	7,25	0/8	
P002	base→BS	2/3	3/3	2/3	3/3	1,58	6,54	1/6	
P003	BS→base	2/3	3/3	2/3	3/3	1,28	7,07	1/9	
P004	base→BS	1/3	3/3	1/3	3/3	1,50	7,50	0/2	
P005	BS→base	3/3	1/3	3/3	2/3	1,50	7,15	1/7	fallita
P006	base→BS	1/3	3/3	1/3	3/3	1,36	6,39	1/6	
P007	BS→base	1/3	3/3	1/3	3/3	1,65	7,39	0/5	
P008	base→BS	2/3	3/3	2/3	3/3	1,53	7,51	2/5	
P009	BS→base	2/3	3/3	2/3	3/3	1,32	6,68	1/6	
P010	base→BS	3/3	3/3	3/3	3/3	1,60	7,44	0/7	
P011	BS→base	1/3	3/3	1/3	3/3	1,51	6,92	0/9	
P012	base→BS	3/3	3/3	3/3	3/3	1,34	6,87	0/8	
P013	BS→base	2/3	3/3	2/3	3/3	1,35	6,79	0/4	
P014	base→BS	2/3	3/3	2/3	3/3	1,63	7,20	1/5	
P015	BS→base	3/3	2/3	3/3	2/3	1,45	7,04	1/9	fallita
P016	base→BS	2/3	3/3	2/3	3/3	1,57	7,05	1/7	
P017	BS→base	2/3	3/3	2/3	3/3	1,50	7,37	1/8	
P018	base→BS	2/3	3/3	2/3	3/3	1,50	7,32	0/6	
P019	BS→base	3/3	3/3	3/3	3/3	1,43	6,65	0/6	
P020	base→BS	1/3	3/3	1/3	3/3	1,65	7,30	0/4	

2. Aggregati

Metrica	risultato (n=20)
NCS osservato, baseline	40/60 — 66,7%
NCS osservato, belief state	57/60 — 95,0%
NCS percepito, baseline	42/60 — 70,0%
NCS percepito, belief state	58/60 — 96,7%
Latenza mediana, baseline	1,48 s
Latenza mediana, belief state	7,07 s
Overhead	+5,59 s
AVOR	11/127 — 8,7%
Fallimenti di estrazione	2/20

Preferenza	Belief state	Baseline
Più credibile	16/20	4/20
Ricordava meglio	16/20	4/20
Più fluida	5/20	15/20
Continuare a parlare	11/20	9/20

3. Test sul campione

Test	Statistica	p	Esito
NCS percepito, ranghi con segno	W = 13,0 (17 coppie non nulle)	0,0017	significativo
Touchpoint dicotomizzati, McNemar esatto	BS 20 · baseline 2	0,00012	significativo
Preferenza, credibilità	16/20	0,012	significativo
Preferenza, memoria	16/20	0,012	significativo
Preferenza, continuare a parlare	11/20	0,824	non significativo
Latenza, ranghi con segno	W = 0,0	0,000088	significativo
Controllo dell'ordine, Mann-Whitney	U = 40,5	0,462	ordine non rilevante

4. Osservazioni

- La corrispondenza fra osservato e percepito è piena in **10 casi su 10**, incluso il caso in cui l'architettura fallisce. È il risultato metodologicamente più solido, perché valida lo strumento di misura e non dipende dalla numerosità.
- L'overhead di latenza è stabile fra +4,96 e +6,00 s, imputabile per intero alle due chiamate di estrazione bloccanti.
- I fallimenti di P005 e P015 hanno una causa identificata e correggibile: l'estrazione, i partecipanti pronunciano una frase che non viene estratta correttamente.
- Due dei tre override reali sono falsi positivi, con la stessa dinamica: il verificatore difende un valore di fiducia obsoleto perché la transizione dell'impegno non è ancora avvenuta.

5. Believability

Dominio	Intervallo	Baseline	Belief state
Comportamento	-1 ... 19	9,2	13,6
Consapevolezza	-2 ... 14	11,0	11,8
Intelligenza	3 ... 15	8,6	11,4
Credibilità complessiva	3 ... 15	7,8	11,2

punteggio per dominio, ottenuto sommando gli item e sottraendo quelli inversi.