

Protocollo Sperimentale

Belief State Node per la coerenza narrativa di NPC guidati da LLM · Andrea Lecini

1. Domanda di ricerca

Gli esperimenti A e B hanno verificato il funzionamento interno del sistema, ma restano misure su meccanismi interni. L'esperimento C risponde alla domanda residua:

Le differenze di coerenza narrativa misurate internamente producono una differenza percepibile da un giocatore reale in una sessione breve di gioco?

H1 — Nella condizione con Belief State Node i partecipanti giudicano coerente una quota maggiore di touchpoint rispetto alla baseline. **H2** — I partecipanti preferiscono la condizione con Belief State Node in un confronto diretto. **H0** — Nessuna differenza rilevabile: i guadagni interni non emergono nell'esperienza a 12 minuti di gioco.

2. Variabili

Tipo	Variabile	Operazionalizzazione
Indipendente	Architettura di memoria (2 livelli, entro i soggetti)	Baseline: Mantella con summary file testuale. Proposta: Mantella con Belief State Node attivo (Context Injection, Contradiction Detector, Prompt Builder, Action Verifier). Unica variabile manipolata
Di controllo	Ordine di presentazione	Controbilanciato: metà dei partecipanti riceve baseline per prima, metà proposta per prima. Essendo lo scenario unico e ripetuto, il controbilanciamento serve a distribuire l'effetto di ripetizione equamente sulle due condizioni anziché a eliminarlo
Dipendente (primaria)	NCS percepito	Proporzione dei 3 touchpoint per sessione in cui il partecipante giudica la reazione dell'NPC coerente con quanto accaduto prima. Item a 5 punti per touchpoint nel questionario post-sessione; dicotomizzato (≥ 4 = coerente) per l'analisi per touchpoint
Dipendente (secondaria)	Preferenza diretta	Scelta binaria forzata al debrief: quale delle due sessioni ha mostrato un personaggio più credibile, più una motivazione libera
Dipendente	Latency overhead percepito	Item a 5 punti sulla fluidità percepita del dialogo, affiancato al Δt medio per turno registrato dai log
Osservate (log)	AVOR, CRR, Δt	Registrate automaticamente lato server nella sola condizione proposta, per collegare il giudizio soggettivo agli eventi interni della sessione

3. Raccolta dati

Campione: 20–25 partecipanti, reclutamento di convenienza, assegnati alternativamente ai due ordini di presentazione. Esclusi chi ha già partecipato ai test pilota o conosce l'architettura. La familiarità pregressa con Skyrim viene raccolta a inizio sessione come possibile covariata.

Scenario: unico e identico nelle due condizioni, costruito sull'arco dell'impegno violato con Lydia e articolato in tre eventi-trigger che garantiscono altrettanti touchpoint verificabili — (1) il giocatore promette a Lydia di aiutarla e il sistema registra l'impegno; (2) il giocatore infrange la promessa, l'impegno transita a violato e propaga l'effetto sulla fiducia; (3) il giocatore torna a parlare con Lydia, ed è il turno in cui si valuta se la reazione riflette quanto accaduto. Una quest dedicata guida il partecipante fra i trigger. Il modello di dialogo e quello di claim extraction restano fissi in entrambe le condizioni, come l'hardware.

Cecità: al partecipante non viene detto quale condizione stia giocando né in cosa differiscono; il debrief avviene solo alla fine.

Sessione, 30 minuti: introduzione, consenso informato e raccolta della familiarità con il gioco (3'); sessione 1 (12'); questionario rapido (2'); sessione 2 nell'altra condizione (12'); questionario finale, preferenza diretta e debrief (1'). I log del server vengono salvati per ogni sessione con identificativo pseudonimizzato.

4. Analisi dei dati

Ogni partecipante gioca entrambe le condizioni, quindi il confronto avviene fra le due sessioni della stessa persona e non fra persone diverse: le differenze individuali pesano molto meno.

NCS percepito. Per ciascun partecipante si confronta la quota di touchpoint giudicati coerenti nella prima e nella seconda sessione, e si valuta se la differenza sia sistematica o compatibile con il caso. Lo stesso confronto viene ripetuto sui singoli touchpoint invece che sul punteggio complessivo: i dati utili triplicano e le differenze piccole diventano visibili.

Preferenza e latenza. Si conta quanti partecipanti scelgono ciascuna condizione e si verifica se lo sbilanciamento superi quello atteso da scelte casuali. Si confrontano poi i tempi medi per turno delle due sessioni, controllando se un eventuale ritardo si rifletta nel giudizio di fluidità: un vantaggio di coerenza pagato con un dialogo percepito come lento non sarebbe un guadagno.

Controllo preliminare. Prima dei confronti si verifica che chi ha giocato in un ordine non abbia risposto diversamente da chi ha giocato nell'altro: se l'ordine incide, il confronto fra le condizioni non è più interpretabile in modo pulito. Per ogni confronto si riporta non solo se una differenza esista, ma anche quanto sia ampia, perché con questo numero di partecipanti una differenza può risultare reale e insieme troppo piccola per avere rilievo pratico.

Limiti da dichiarare nella tesi. Lo scenario è unico e viene giocato due volte dallo stesso partecipante: nella seconda sessione la trama è nota, e questo produce un effetto di ripetizione che il controbilanciamento distribuisce fra le condizioni ma non annulla. Va quindi verificato che l'effetto dell'ordine non sia significativo prima di interpretare l'effetto della condizione. Con 20–25 partecipanti lo studio resta sottodimensionato per effetti piccoli: i risultati di C vanno presentati come segnale indicativo a supporto di A e B, non come validazione conclusiva a sé stante. L'effetto novità di interagire con un NPC che ricorda può inoltre gonfiare la preferenza soggettiva indipendentemente dalla qualità tecnica; la motivazione libera raccolta al debrief serve anche a individuare questo caso. Una sessione di 12 minuti resta infine lontana dall'orizzonte lungo in cui l'architettura mostra il proprio vantaggio in B.